

EKSAMENSOPPGAVE

Eksamen i:	STA-0001 Brukerkurs i statistikk 1
Dato:	4. juni 2019
Klokkeslett:	15:00-19:00
Sted:	Hall del 2 Kraft sportssenter
Tillatte hjelpemidler:	Alle trykte og skrevne samt kalkulator
Type innføringsark (rute/linje):	Rute
Antall sider inkl. forside:	4
Kontaktperson under eksamen:	Elinor Ytterstad
Telefon/mobil:	775 44015
Vil det bli gått oppklaringsrunde i eksamenslokalet? Svar: JA Hvis JA: ca. kl. ____ 1600 ____	

NB! Det er ikke tillatt å levere inn kladdepapir som del av eksamensbesvarelsen. Hvis det likevel leveres inn, vil kladdepapiret bli holdt tilbake og ikke bli sendt til sensur.

Oppgavesettet består av 10 delpunkter som alle teller likt ved bedømming.
Det brukes desimalpunktum i dette oppgavesettet.

Oppgave 1

Per produserer bjørkeved i 60 liters sekker.

De fire første sekkene veier (i kg): 36.0, 38.5, 34.0, 35.5.

- a)
- Regn ut medianen og gjennomsnittsvekten til vedsekkene.
 - Regn ut empirisk standardavvik s og finn et 95% konfidensintervall for standardavviket σ . Avrund til to desimaler.
Hvilken fordelingsantagelse må gjøres?

Løsningsforslag:

Median av 34, 35.5, 36, 38.5: $\frac{35.5+36}{2} = 35.75$

Gjennomsnitt: $\frac{144}{4} = 36$

Datamateriale:

x	$x - \bar{x}$	$(x - \bar{x})^2$
36.0	0	0
38.5	2.5	6.25
34.0	-2	4
35.5	-0.5	0.25
sum	144	10.50

Empirisk varians: $s^2 = \frac{10.50}{4-1} = 3.5$

og da blir standardavviket: $s = \sqrt{3.5} = 1.87$

Må først finne et 95% KI for σ^2 der vi bruker kjikvadratfordeling med $n - 1 = 3$ frihetsgrader. Finner $\chi_{0.025}$ og $\chi_{0.975}$ i tabell E.6:

$N = \frac{(4-1)s^2}{\chi_{0.025}} = \frac{10.5}{9.35} = 1.12$ og $\bar{O} = \frac{(4-1)s^2}{\chi_{0.975}} = \frac{10.5}{0.22} = 47.73$.

Et 95% KI for σ blir da $(\sqrt{1.12}, \sqrt{47.73})$, altså (1.06, 6.91).

Fordelingsantagelse: Y er normalfordelt eller tilnærmet normalfordelt.

Nyhogd ved inneholder mye vann og må tørke før det er egnet som brensel.
Per har lagret vedsekkene utendørs i ett år og måler Y = fuktigheten i 9 tilfeldig valgte vedskier. (Det oppgis ikke her hvordan fuktighet måles og heller ikke hva måleenheten for fuktighet er.)

Vi skal anta at $Y \sim N(\mu, \sigma)$ med ukjent σ .

Resultatet av de $n = 9$ målingene ble: $\bar{y} = 20.8$ og $s = 0.90$

- b)
- Finn et estimat for forventet fuktighet μ .
 - Regn ut et 90 % konfidensintervall for μ .

Løsningsforslag:

Estimert forventet fuktighet μ : $\hat{\mu} = \bar{y} = 20.8$

Vi har normalfordelte data med ukjent standardavvik σ , da bruker vi t -fordelingen med $n - 1 = 8$ frihetsgrader. $N = \bar{y} - t_{0.05} \frac{s}{\sqrt{9}} = 20.8 - 1.860 \cdot \frac{0.90}{3} = 20.24$

Øvre grense: $\bar{O} = 20.8 + 1.860 \cdot 0.30 = 21.36$

Et 90% KI for μ : (20.24, 21.36)

I følge Norsk standard NS4414 skal fuktigheten i salgbar ved ikke overstige 20.

- c)
- Undersøk med hypotesetest om Pers ved har for høy fuktighet.
 Bruk 5 % signifikansnivå.
 Formulér passende hypoteser, regn ut testobservator og konkludér.

Løsningsforslag:

Hypoteser: $H_0 : \mu \leq 20$ mot $H_1 : \mu > 20$

Bruker t -test med 8 frihetsgrader.

Da skal en forkaste H_0 hvis $T > 1.860$

Testobservator, T -test: $T = \frac{20.8 - 20}{\frac{s}{\sqrt{9}}} = \frac{0.8}{0.30} = 2.67$

Obersvert verdi av testobservator $T > 2.67$ er større enn 1.860 og H_0 forkastes på 5% nivå.

Det er grunnlag i data til å hevde at Pers ved har for høy fuktighet.

- d)
- Forklar hvordan konfidensintervallet i b) kan brukes til å gjennomføre testen i c).
 Finn også en omtrentlig p -verdi for testresultatet i c).

Løsningsforslag:

Et 90% konfidensintervall for μ kan brukes direkte i test av tosidig alternativ hypotese på 10% nivå (100-90).

Her har vi imidlertid en ensidig alternativ hypotese: $\mu > 20$, og da forkastes nullhypotesen på 5% nivå (merk endringen fra 10% nivå test til 5% test) hvis hele konfidensintervallet ligger i H_1 området $\mu > 20$. Det er tilfelle her og vi kan konkludere fra 90% konfidensintervallet at nullhypotesen forkastes på 5% nivå.

Eksakt P-verdi er $P(T > 2.67)$. Bruker t-fordelingstabellen for 8 frihetsgrader og finner de to nærmeste verdiene. Det er $P(T > 2.896) = 0.01$ og $P(T > 2.306) = 0.025$.
Dermed er: $0.01 < \text{P-verdi} < 0.025$.

Noe av veden Per produserte ble ikke pakket i sekker, men stablet og lagret samme sted som sekkene.

Fuktigheten (X) i $n = 10$ tilfeldig valgte vedskier av denne veden ble også målt: $\bar{x} = 20.3$, $s_x = 0.93$.

- e) Undersøk med hypotesetest om det er grunnlag for å hevde at løs ved (ikke lagret i sekker) tørker bedre enn den i sekker.
Hvilke fordelingsantagelser må du gjøre?
Bruk 5% signifikansnivå.

Løsningsforslag: Forutsetter uavhengige og normalfordelte X og Y med identisk varians σ^2 .

Variansen σ^2 er ukjent og estimeres med: $s_{pooled}^2 = \frac{(9-1)0.90^2 + (10-1)0.93^2}{9+10-2} = 0.839$

Vi gjennomfører en uparet T-test.

$$H_0 : \mu_y \leq \mu_x \text{ mot } H_1 : \mu_y > \mu_x$$

$$\text{Testbobservatoren } T = \frac{\bar{Y} - \bar{X}}{s_{pooled} \sqrt{\frac{1}{9} + \frac{1}{10}}}$$

er t-fordelt med $9 + 10 - 2 = 17$ frihetsgrader.

Forkaster nullhypotesen hvis $T > 1.740$ (fra tabell E.5).

$$\text{Regner ut verdien av testobservator: } T = \frac{20.8 - 20.3}{s_{pooled} \sqrt{\frac{1}{9} + \frac{1}{10}}} = 1.19 .$$

Konklusjon: Nullhypotesen forkastes ikke på 5% nivå. Det er ikke grunnlag i data for å hevde at løs ved tørker bedre enn den som lagres i sekker.

Alle tall i denne oppgaven er oppdiktet.

Oppgave 2

Lyskilder med LED-teknologi har lange levetider sammenlignet med lyspærer med glødetråder. La T være levetid (i år) for ei LED-lyspære fra en produsent som oppgir at forventet levetiden er 5.7 år (ca 50000 timer).

Vi skal anta at T er eksponentialfordelt med forventningsverdi 5.7 år. Det vil si at

$$f(t) = \frac{1}{5.7} e^{-\frac{t}{5.7}} = 0.1754 \cdot e^{-0.1754 \cdot t} \quad \text{for } t > 0$$

og

$$P(T \leq t) = F(t) = 1 - e^{-0.1754 \cdot t} \quad \text{for } t > 0$$

- a) • Bruk kjente egenskaper ved eksponentialfordelingen og finn standardavviket til T .

Regn ut og vis at (avrundet til to desimaler):

- Sannsynligheten for at ei tilfeldig valg LED-pære skal slutte å virke (dø) før det har gått ett år, er 0.16
- $P(T \leq 2) = 0.30$

Løsningsforslag:

Standardavviket til T er identisk med forventningsverdien i denne eksponensialfordelingen, altså 5.7 år.

$$P(T \leq 1) = F(1) = 1 - e^{-0.1754 \cdot 1} = 0.16$$

$$P(T \leq 2) = F(2) = 1 - e^{-0.1754 \cdot 2} = 0.30$$

I Annes nye leilighet er det 10 slike LED-lys i stuetaket.

Vi forsetter gjennom hele oppgaven at lysene er tent 24 timer i døgnet.

La X være antall taklys som har sluttet å virket før det har gått 2 år.

- b)
- Hvilken fordeling har X , begrunn svaret. Hvilke antagelser må du gjøre?
 - Regn ut forventet antall taklys som har sluttet å virke før to år.
 - Vis at $P(X \geq 6) = 0.047$.

Løsningsforslag:

Antar lysene virker uavhengig av hverandre, f.eks at det ikke er noe med strømforsyningen som påvirker alle lys. Antar også at alle lys har samme sannsynlighet for å slutte å virke, $p = 0.30$ (hentet fra a)).

Da er X binomisk fordelt med $n = 10$ og $p = 0.30$.

Forventning i binomisk fordeling er: $E(X) = np = 10 \cdot 0.30 = 3$.

Bruker tabell E.1: $P(X \geq 6) = 1 - P(X \leq 5) = 1 - 0.953 = 0.047$.

Anne er skeptisk til den oppgitte levetiden, og vil undersøke med hypotesetest om den er mindre enn 5.7 år. Anne trenger mer data, og avtaler derfor med tre naboer i identiske leiligheter om å la taklysene være tent 24 timer i døgnet. Til sammen har de $n = 40$ LED-lys, og etter ett år viser det seg at $Y = 12$ av taklysene har sluttet å virke.

Her kan du bruke at Y er en binomisk fordelt variabel.

- c) Formulér passende hypoteser og gjennomfør testen på 5 % signifikansnivå. Hva blir konklusjonen av testen?

Løsningsforslag:

$Y \sim \text{Bino}(40, 0.16)$ der $p = 0.16$ er hentet fra a).

Variansen er da $np(1 - p) = 40 \cdot 0.16 \cdot 0.84 = 5.376$, altså større enn 5 og vi kan bruke normaltilnærming.

$H_0 : p \leq 0.16 \quad H_1 : p > 0.16$ (dvs forventet levetid < 5.7 år).

Forkast nullhypotesen dersom $Z \geq 1.645$

Vi gjennomfører testen:

Testobservator: $Z = \frac{12 - 40 \cdot 0.16}{\sqrt{5.376}} = 2.42$

Konklusjon: $Z = 2.42$ er større enn 1.645 og H_0 forkastes på 5 % signifikansnivå. Det er grunnlag for å tro at den oppgitte levetiden er for høy.

Oppgave 3

I forbindelse med en helseundersøkelse måles blodtrykket (Y) til 6 tilfeldig valgte kvinner. Kvinnens alder er også registrert.

Alder x	25	35	45	55	65	75
Blodtrykk y	108	114	124	143	158	166

Det oppgis at: $\sum_{i=1}^6 (x_i - \bar{x})(y_i - \bar{y}) = 2205$, $\sum_{i=1}^6 (y_i - \bar{y})^2 = 2843.5$, $\sum_{i=1}^6 y_i = 813$ og $\sum_{i=1}^6 (x_i - \bar{x})^2 = 1750$.

- a)
- Lag et spredningsplott av datamaterialet.
 - Regn ut korrelasjonskoeffisienten r .
 - Er det rimelig å anta en lineær sammenheng mellom alder og blodtrykk? Begrunn.

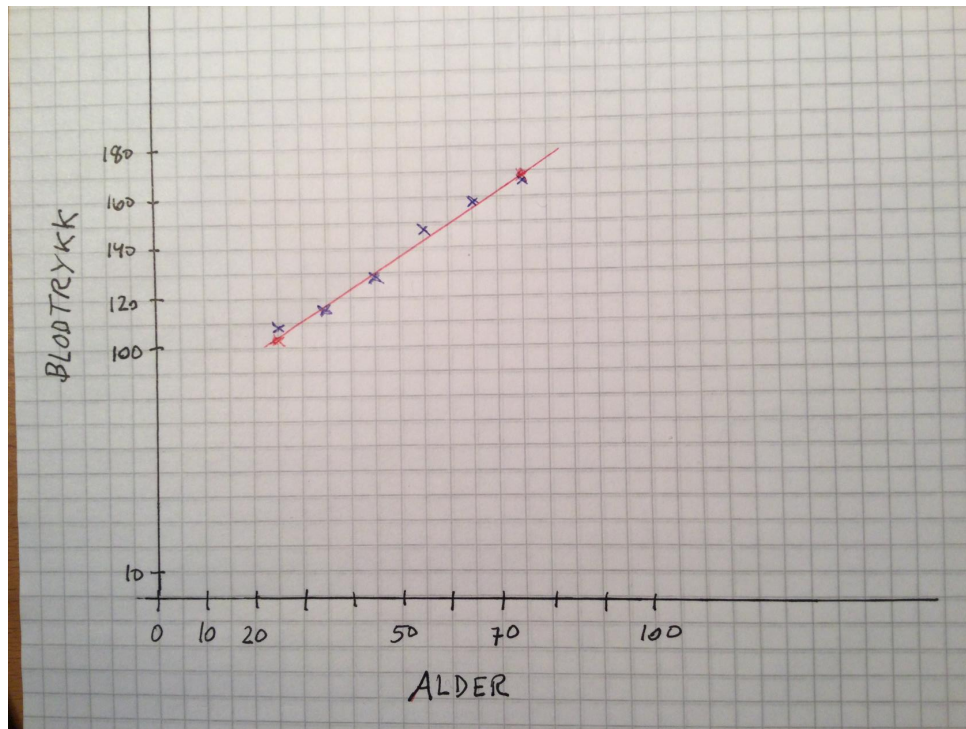
Løsningsforslag:

- Spredningsplott: Se etter b)
- Korrelasjonskoeffisienten $r = \frac{2205}{\sqrt{1750}\sqrt{2843.5}} = 0.9885$.
- Ja. Korrelasjonskoeffisienten er veldig nær 1. Det er bare mulig hvis sammenhengen er lineær (rettlinjet)

- b)
- Regn ut regresjonslinja og tegn den inn i spredningsplottet i a).
 - Hvordan tolker du stigningstallet til linja?

Løsningsforslag:

- $\hat{\beta} = \frac{2205}{1750} = 1.26$
 $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} = \frac{813}{6} - 1.26 \cdot 50 = 72.5$
 Regresjonslinja er: $\hat{y} = 72.5 + 1.26x$
 Regner ut to punkt på linja og tegner den inn i spredningsplottet.
 $x = 25$ gir $\hat{y} = 104$
 $x = 75$ gir $\hat{y} = 167$
- Blodtrykket hos kvinner generelt øker i gjennomsnitt med 1.26 måleenheter (mmHg) hver år kvinnen eldes.



De to punktene som er beregnet for å plassere regresjonslinja, er markert med rødt.